

# Sensado Compresivo con Single Pixel Camera

Joaquín Farias, *Estudiante*

**Resumen**—En Este informe se presenta una simulación de sensado compresivo utilizando Single Pixel Camera. Además, se explicará cómo es el funcionamiento de este modelo y se estudiarán los resultados y los grados de error.

**Palabras clave**— Compressed Sensing, Pixel Single Camera, Wavelets, Procesamiento de imágenes.



## 1 INTRODUCCIÓN

Hoy en día nos encontramos en la una era digital donde es muy apremiante transmitir y adquirir información de distintos dispositivos. Es por lo anterior que resulta crucial comprimir la información para su transferencia y almacenamiento.

En el contexto anterior, el caso de las imágenes no se queda fuera donde se intenta comprimir la imagen tratando de hacer lo más fidedigna su reconstrucción. Existen dos tipos de compresión: con y sin pérdida, pero además existe un relativamente nuevo paradigma: el sensado compresivo o *compressed sensing*, en inglés.

Este Compressed Sensing, ha permitido muestrear tasas muy por debajo de las establecidas por las técnicas convencionales. El enfoque consiste en modelar las estructuras multicanal como imágenes que presentan una descomposición “sparse” (interpretar la información importante en pocos componentes) en algún dominio transformado y utilizar esta información para reconstruir la imagen original a partir de un muestreo subcrítico y no estructurado.

Además, este sistema ha dado lugar el diseño de nuevos escenarios de adquisición de datos, es decir, ofrece un método para la adquisición y compresión de datos de manera simultánea.

Basado en la teoría de Compressed Sensing y el funcionamiento de la Single Pixel Camera, es propuesto el sistema óptico 4f, el cual permite realizar proyecciones de manera simultánea. La configuración considera una escena como imagen de entrada, un lente, un plano de Fourier, un segundo lente y una imagen de salida, todos estos elementos separados entre sí por las distancias focales correspondientes a cada lente.

una señal es necesario aplicar el teorema de Nyquist-Shannon, el cual consiste en tomar un número de muestras de la señal original mayor al doble del ancho de banda que ésta posea.

El sensado compresivo sale de este paradigma y permite reconstruir una imagen con menos datos. Pero, tiene una salvedad importante, este relativamente nuevo método solo funciona con datos denominados “sparse”. Este término quiere decir que los datos a adquirir deben tener pocos datos importantes, para así poder representar la imagen con pocos datos. En otras palabras, se asume que debe ser comprimible. Además, En los últimos años, el concepto de “sparsity” ha tomado gran relevancia con el objetivo de inferir los píxeles (en el marco de procesamiento de imágenes) faltantes a partir de los datos observados e información a priori, puesto que los objetos de interés típicamente están contenidos en un subconjunto de dimensión considerablemente más pequeña que la imagen en cuestión.

Finalmente, la teoría dicta que se debe muestrear con un muestreo aleatorio, siguiendo la siguiente fórmula:

$$y = H \cdot x$$

Donde  $y$  corresponde al vector de datos comprimidos de  $x$  por medio de  $H$ ,  $H$  corresponde a la matriz de mediciones y  $x$  al vector de datos sparse que se va a comprimir.

En la figura 2-1 se puede apreciar un bosquejo con todas las partes de esta teoría, se nota una afirmación muy importante

$$K < M \ll N$$

Cuando esta afirmación es cierta, la compresión ocurre. Esto es debido a que las dimensiones de la matriz  $y$  y  $M$  son bastante más pequeñas que las de la matriz  $N$ .

## 2 DESCRIPCIÓN DEL ALGORITMO DE SENSADO COMPRESIVO Y SINGLE PIXEL CAMERA

En este capítulo se describirá la teoría del sensado compresivo, además del escenario de la Single Pixel Camera. Además, se presentarán los pasos a seguir para formular el algoritmo.

### 2.1 Sensado compresivo

Para lograr habitualmente la reconstrucción exacta de






Fig. 2-1. Esquema de sensado compresivo.



(a)



(b)

Fig. 2-2. (a) Escaneo de un pixel a la vez. (b) Escaneo aleatorio.

## 2.2 ESPARCIMIENTO DE IMAGEN

Para esparcir la imagen se ocuparán Wavelets, esto se debe hacer porque se sabe que, en general, las imágenes no son datos "sparse" debido a que se tiene información de manera densa en todos los píxeles de la foto.

Aunque lo anterior es cierto, también se sabe que la información importante o de interés se concentra en pocos píxeles de la foto, dado que los otros pueden ser valores redundantes o que no aportan información importante. Entonces se ocupa la transformada de Wavelets para poder hacer que los datos importantes se concentren en algunos pocos píxeles.

## 2.2 SINGLE PIXEL CAMERA

Se sabe que hoy en día existen variados tipos de cámaras de las cuales la mayoría funciona con millones de sensores de luz. Por otro lado, la single pixel camera enfoca la luz entrante en un solo píxel. Lo que marca la diferencia al utilizar solo un píxel es el controlar qué partes de la luz entrante se dejan pasar al sensor. Una forma de realizar esto, sería el cubrir todo el arreglo de píxeles a excepción de uno a la vez y hacer la medición, para luego volver a hacerlo todas las veces necesarias hasta cubrir toda la imagen.

Otra opción es hacer un muestreo con un número mucho menor de píxeles en comparación con la teoría de muestreo estándar de Nyquist. Esta forma de muestreo reconstruye un vector  $x$  a partir de mediciones lineales, en donde existen un número mucho menor de mediciones que valores de la señal. En este caso son generados pseudo vectores aleatorios  $k$  y que representan mapas de píxeles.

En la imagen 2-2, se muestra el escaneo de un pixel a la vez y la opción de escaneo de manera aleatoria.

Para hacer nuestra simulación, se obtendrá una matriz aleatoria de muestras con la función de Matlab *rand* con una distribución de Bernoulli, es decir con 1s y 0s.

## 2.3 RECONSTRUCCIÓN DE IMAGEN

Para reconstruir la imagen se debe ocupar un sistema de minimización. En general, se elige la minimización  $l_1$  para por la complejidad de la minimización con la normal  $l_0$ . Esta norma  $l_1$  se puede representar en el plano como un rombo cuyos vértices se encuentran justo en los ejes, con esto se puede encontrar el valor más sparse de los datos tocando este valor primero. En la figura 2-3 se muestra un ejemplo de la normal  $l_1$ .

En nuestro algoritmo se ocupará la técnica de regularización *lasso*, dado que se intentó implementar otra como *magic* o *nesta*, pero no se llegó a buenos resultados.

*Lasso* es una técnica de regulación para realizar la regresión lineal, la cual es usada para reducir el número de predictores en un modelo de regresión, identificar predictores importantes y seleccionar predictores redundantes. Además, realiza la selección de variable y proporciona una regularización para mejorar la precisión de la predicción y la interpretabilidad del modelo que produce, esto se genera cuando se establece una  $\lambda$ , parámetro de

regularización positivo, en un número estrictamente entre 0 y 1.





Fig. 2-1. Ejemplo normalización  $l_1$ .



(a)

### 3 PRUEBAS Y ANÁLISIS

En este capítulo se harán presentarán las pruebas hechas, además de los análisis de error del algoritmo propuesto. Cabe destacar que se probó con varias cantidades de muestrear para poder formar la gráfica de error y se eligió las imágenes con muestras que reflejen de mejor manera esta grafica.

#### 3.1 Resultados y ejemplos de reconstrucción de imagen comprimida

Los resultados de imágenes reconstruidas se presentan en la figura 3-1, donde se muestra la imagen original juntos con dos reconstrucciones con 100 y 300 muestras respectivamente. Esta cantidad de muestras quiere decir la cantidad de vectores aleatorios con los cuales se multiplica el vector de datos  $x$  para obtener la matriz  $y$ . Dicho de otra forma la matriz  $y$  tiene dimensiones  $M \times 1$ , esto se ve claramente en la figura 2-1.


Se puede notar de las pruebas que la imagen con 100 muestras tiene un notable deterioro en relación con la imagen original mostrando pixeles fantasmas con valor incorrectos.

También, se nota de imagen con 300 muestras que ya la reconstrucción es mucho mejor y casi no presenta error con relación a la imagen original.

#### 3.2 Análisis de error

Para analizar el error se ocupó el error cuadrático medio promediando este valor en todos los pixeles de la comparación de la imagen reconstruida con la original. Además, este analices se hizo para distintas cantidades de muestras. En la figura 3-2 se puede apreciar el error para valor de entre 2 y 1500 muestras.

En la imagen se puede apreciar como el error baja de manera considerable cuando hay más menos 300 muestras, por eso se eligió mostrar la imagen con este valor en la figura 3-1. Además, se nota que cuando llega aproximadamente a un valor de 500 muestras el error casi no cambia y solo fluctúa en valor muy bajos.




(b)



(c)

Fig. 3-1 Ejemplo del algoritmo con una imagen. (a) Imagen original. (b) Imagen con 100 muestras. (c) imagen con 300 muestras.



**Joaquín Farias Muñoz** Estudiante de ingeniería civil electrónica, Pontificia Universidad católica de Valparaíso.

Fig. 2-1. Error de la imagen reconstruida con 1 a 1500 muestras.

## 6 CONCLUSIONES

En este trabajo se hizo un estudio del sensado compresivo utilizando el ambiente de *single pixel camera*. Se obtuvieron reconstrucciones de imágenes con distintas cantidades de muestras, además de una gráfica de error que evalúa que cantidad de muestras sería óptima.

Según lo anterior la cantidad óptima de muestras rondaría las 300 para una compresión mayor, pero con alta fidelidad de la imagen.

Se nota que el sensado compresivo es bastante efectivo en compresión, además de que no se necesita tener los datos adquiridos para comprimirlos, ya que este método hace los dos procedimientos de manera simultánea.

El problema que vio en este nuevo paradigma es el ambiente de sensado, es decir, no siempre se puede tener sensado de manera aleatoria. Se podría requerir un esfuerzo y gasto monetario para poder lograr lo anterior en muchas aplicaciones.

## REFERENCIAS

- [1] Boyd, S., & Vandenberghe, L. (2018). Introduction to applied linear algebra: vectors, matrices, and least squares. Cambridge university press.
- [2] Candès, E. J., & Wakin, M. B. (2008). An introduction to compressive sampling. *IEEE signal processing magazine*, 25(2), 21-30.
- [3] Lochocki, B., Gambín, A., Manzanera, S., Irlés, E., Tajahuerce, E., Lancis, J., & Artal, P. (2016). Single pixel camera ophthalmoscope. *Optica*, 3(10), 1056-1059.
- [4] Duarte, M. F., Davenport, M. A., Takhar, D., Laska, J. N., Sun, T., Kelly, K. F., & Baraniuk, R. G. (2008). Single-pixel imaging via compressive sampling. *IEEE signal processing magazine*, 25(2), 83-91.
- [5] Romberg, J. (2008). Imaging via compressive sampling. *IEEE Signal Processing Magazine*, 25(2), 14-20.
- [6] Chen, H., Weng, Z., Liang, Y., Lei, C., Xing, F., Chen, M., & Xie, S. (2014, June). High speed single-pixel imaging via time domain compressive sampling. In *CLEO: Applications and Technology* (pp. JTh2A-132). Optical Society of America.